

4. Laboratorijska vježba: Multivarijatan financijski vremenski nizovi

Siječanj 2023.

Upute

U ovoj bilježnici dana je priprema sa svim uputama za 4. laboratorijsku vježbu iz predmeta Obrada informacija - uz bilježnicu su dostupni i podaci u datoteci `ETFprices.csv`.

Vaš zadatak je u bilježnicu na odgovarajuća mjesta dopisati kod Vašeg rješenja, te odgovore na zadana pitanja.

Riješenu bilježnicu potrebno je predati kao izvještaj u .pdf formatu na Moodle najkasnije do 24.1.2023. u 23:59h. Datoteka koju predajete se mora zvati *Prezimelme.pdf*.

Uvod

U laboratorijskoj vježbi razmatra se dinamika cijena vrijednosnica na financijskim tržištima. Dane su povijesne dnevne cijene 8 ETF-ova (eng. *exchange traded fund*) koji prate određene dioničke, obvezničke ili druge indekse.

Ticker	Fond	Klasa imovine
SPY	SPDR S&P 500 ETF Trust	Equity: U.S. - Large Cap
VTI	Vanguard Total Stock Market ETF	Equity: U.S. - Total Market
QQQ	Invesco QQQ Trust	Equity: U.S. - Large Cap
VEA	Vanguard FTSE Developed Markets ETF	Equity: Developed Markets Ex-U.S. - Total Market
AGG	iShares Core U.S. Aggregate Bond ETF	Fixed Income: U.S. - Broad Market, Broad-based Investment Grade
BND	Vanguard Total Bond Market ETF	Fixed Income: U.S. - Broad Market, Broad-based Investment Grade
LQD	iShares iBoxx USD Investment Grade Corporate Bond ETF	Fixed Income: U.S. - Corporate, Broad-based Investment Grade
VCIT	Vanguard Intermediate-Term Corporate Bond ETF	Fixed Income: U.S. - Corporate, Broad-based Investment Grade Intermediate

Pri modeliranju zajedničkog kretanja i rizika vrijednosnica, najčešće se koriste povrati:

$$R(t) = \frac{S(t) - S(t-1)}{S(t-1)},$$

gdje je $S(t)$ cijena vrijednosnice u danu t . U sklopu ove laboratorijske vježbe cilj je analizirati kretanje danih ETF-ova i izračunati glavne komponente (PCA) koje utječu na njihovu dinamiku. Laboratorijsku vježbu je potrebno riješiti unutar ove bilježnice i predati riješenu bilježnicu kao izvještaj.

```
from google.colab import drive
import os

drive.mount('/content/drive')

Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

import pandas as pd
from matplotlib import pyplot as plt

prices = pd.read_csv("/content/drive/MyDrive/Colab Notebooks/ETFprices.csv")
prices.set_index('Time', inplace=True)
prices.index = pd.to_datetime(prices.index)

prices.head()
```

	SPY	VTI	QQQ	VEA	AGG	BND	LQD	VCIT
Time								
2022-01-10	458.078430	231.924240	377.329224	49.100105	109.858536	81.452065	125.620148	88.636536
2022-01-11	462.250763	234.236588	382.997437	49.682655	110.063812	81.617920	125.998177	88.753113
2022-01-12	463.500458	234.600677	384.516266	50.216679	110.063812	81.588654	125.910950	88.811386
2022-01-13	457.114075	231.166565	374.897156	49.857430	110.259331	81.725235	126.308357	88.976517
2022-01-14	457.301086	231.255142	377.229950	49.740917	109.643509	81.276474	125.193680	88.481125

Zadatak 1 - Računanje korelacijske matrice i matrice kovarijance povrata

1.1. U prvom zadatku ove laboratorijske vježbe potrebno je prvo iz danih cijena (gore učitanih u Pandas DataFrame) izračunati dnevne povrate za sve pojedine vrijednosnice (prateći formulu danu u uvodu).

Izračunajte srednje povrate i volatilnost (standardnu devijaciju povrata) za svaku pojedinu vrijednosnicu. Pri analizi srednjih povrata i volatilnosti, te se brojke često *anualiziraju* - to znači da se srednji povrati pomnože s 252 (cca. broj trgovinskih dana u godini), a volatilnost s $\sqrt{252}$. Izračunajte anualizirane srednje povrate i volatilnosti te rezultate ispišite u konzolu.

```
#Vaš kod ide ovdje
import numpy as np
from numpy import linalg as LA
from matplotlib import pyplot as plt
```

```

import math
# print(prices.shift(1))

povrati = (prices - prices.shift(1))/prices.shift(1)
# print(povrati)

print("Srednji povrati:", povrati.mean() * 252, '\n\nVolatilnosti:', povrati.std() * math.sqrt(252))

Srednji povrati: SPY      -0.138092
VTI      -0.148174
QQQ      -0.283459
VEA      -0.092129
AGG      -0.098139
BND      -0.099603
LQD      -0.135087
VCIT      -0.104975
dtype: float64

Volatilnosti: SPY      0.243655
VTI      0.249912
QQQ      0.322061
VEA      0.224686
AGG      0.081305
BND      0.080695
LQD      0.123953
VCIT      0.095454
dtype: float64

```

1.2 Koristeći dnevne povrate, potrebno je izračunati matricu kovarijance Σ i matricu korelacije C svih ETF-ova. Kovarijancu i korelaciju moguće je iz podataka izračunati koristeći Pandas, ali i NumPy ili neke druge biblioteke. Matrice ispišite u konzolu ili vizualizirajte.

```

#Vaš kod ide ovdje

print("Matrica kovarijacije,  $\Sigma$ :\n")
matrica_kovarijacije = povrati.cov()
print(matrica_kovarijacije)

print("\n\nMatrica korelacije,  $C$ :\n")
matrica_korelacije = povrati.corr()
print(matrica_korelacije)

import seaborn as sns
sns.heatmap(matrica_korelacije, annot = True)

```

	SPY	VTI	QQQ	VEA	AGG	BND	LQD
SPY	0.000236	0.000241	0.000301	0.000189	0.000026	0.000026	0.000057
VTI	0.000241	0.000248	0.000310	0.000195	0.000027	0.000027	0.000059

▼ Zadatak 2 - Analiza glavnih komponenti

2.1. Izračunajte svojstvene vektore i pripadajuće svojstvene vrijednosti matrice kovarijance povrata Σ (svojstvenu dekompoziciju možete pronaći u sklopu biblioteke NumPy <https://numpy.org/doc/stable/reference/generated/numpy.linalg.eig.html>). Poredajte komponente padajućim po svojstvenim vrijednostima i prikažite svojstvene vrijednosti grafički.

```


#Vaš kod ide ovdje

eigenvalues, eigenvectors = np.linalg.eig(matrica_kovarijacije)

# Sort eigenvalues in descending order
idx = eigenvalues.argsort()[::-1]
eigenvalues = eigenvalues[idx]
eigenvectors = eigenvectors[:,idx]

# Plot the eigenvalues
plt.bar(range(len(eigenvalues)), eigenvalues)
plt.xlabel('Component')
plt.ylabel('Eigenvalue')
plt.show()

```



2.2. Izračunajte koliki udio varijance objašnjavaju prve dvije komponente?



#Vaš kod ide ovdje

```
# Calculate proportion of explained variance by first two components
explained_variance = eigenvalues[:2].sum() / eigenvalues.sum()
print("Proportion of explained variance by first two components: {:.2f}%".format(explained_variance * 100))
```

Proportion of explained variance by first two components: 95.04%

2.3. Komponente PCA će u financijama često opisivati neke zajedničke faktore u podacima, što je moguće analizirati promatranjem pojedinih elemenata svojstvenih vektora. Ako je neki element određenog svojstvenog vektora velik po magnitudi (pozitivan ili negativan), to znači da ta komponenta opisuje odgovarajuću vrijednosnicu i objašnjava njenu varijancu, za razliku od slučaja kad je element blizu 0, što znači da razmatrana vrijednosnica ne ovisi previše o toj komponenti. Ispišite (ili grafički prikažite) elemente prva dva svojstvena vektora. Pritom pripazite na to što vraća funkcija koju koristite i u kojoj se dimenziji (stupac ili red) nalaze svojstveni vektori.

S obzirom na to koje vrijednosnice opisuju prve dvije komponente, možete li zaključiti koju klasu imovine opisuje prva komponenta (koja odgovara prvom svojstvenom vektoru), a koju klasu druga komponenta? (odgovor napišite u nastavku)

#Vaš kod ide ovdje



```
first_eigenvector = np.abs(eigenvectors[:,0])
second_eigenvector = np.abs(eigenvectors[:,1])

# Plot the first eigenvector
plt.bar(povrati.columns, first_eigenvector)
plt.xlabel("ETFs")
plt.ylabel("Absolute value of first eigenvector")
plt.show()

# Plot the second eigenvector
plt.bar(povrati.columns, second_eigenvector)
plt.xlabel("ETFs")
plt.ylabel("Absolute value of second eigenvector")
plt.show()

# Get the absolute values of the first two eigenvectors
first_eigenvector = np.abs(eigenvectors[:,0])
second_eigenvector = np.abs(eigenvectors[:,1])

print(first_eigenvector)
print(second_eigenvector)
```



[0.46490446 0.47791577 0.60770765 0.39004316 0.06152524 0.06105256

Vjerujem da su najutjecajnije vrijednosnice one s najvećim apsolutnim vrijednostima eigenvectora -> QQQ, VTI za 1. svojstveni vektor -> LQD, VCIT za 2. svojstveni vektor

2.4. Ponovite prethodnu analizu za matricu korelacije povrata C . Koliki udio varijance u tom slučaju objašnjavaju prve dvije komponente? Usporedite elemente prva dva svojstvena vektora u ovom slučaju i u prethodnom slučaju - razlikuje li se interpretacija i kako? (odgovor napišite u nastavku)

#Vaš kod ide ovdje

```
# Compute eigenvalues and eigenvectors of the correlation matrix
eigenvalues, eigenvectors = np.linalg.eig(matrica_korelacije)

# Sort the eigenvectors and eigenvalues in descending order
idx = eigenvalues.argsort()[::-1]
eigenvalues = eigenvalues[idx]
eigenvectors = eigenvectors[:,idx]

# Calculate the percentage of variance explained by the first two components
explained_variance = eigenvalues[:2]/sum(eigenvalues)
print("Percentage of variance explained by the first two components:")
print(explained_variance[0] + explained_variance[1])
```

Percentage of variance explained by the first two components:
0.9585861905581966

▼ Zadatak 3 - Svojstveni portfelji

U primjeni PCA i svojstvenoj dekompoziciji kovarijance u financijama, svojstveni vektori se često zovu i tzv. svojstveni portfelji.

Općenito, portfelj je vektor $w = [w_1, \dots, w_N]$ u kojem svaki element predstavlja težinu ili udio kapitala u određenoj vrijednosnici. Često je dobro pomnožiti njihove težine s predznakom njihove sume - na taj način zapravo samo "okrećemo" predznak svojstvenog vektora tako da mu je suma pozitivna (konačni PCA rastav je i dalje isti ako svojstveni vektor pomnožimo s -1). Također, dobro je i skalirati svojstvene portfelje sa sumom njihovih apsolutnih vrijednosti:

$$\tilde{w}_i = \frac{w_i}{\sum_j^N |w_j|}.$$

Na taj način se osigurava da visoke magnitude pojedinih elemenata ne uzrokuju velike razlike u volatilnostima svojstvenih portfelja.

Ukoliko znamo povrate $R \in \mathbb{R}^{T \times N}$ (gdje je $R_i \in \mathbb{R}^T$ vektor povrata za vrijednosnicu i) za N vrijednosnica u nekom vremenskom periodu od T dana, povrate portfelja w u tom istom periodu možemo izračunati kao:

$$R_p = \sum R_i w_i = R \cdot w.$$

Izračunajte skalirane svojstvene portfelje \tilde{w} koji proizlaze iz prve dvije glavne komponente dobivene iz matrice kovarijance Σ . Za ta dva svojstvena portfelja izračunajte povijesne povrate kroz razmatrani period. Grafički prikažite vremensko kretanje njihovih vrijednosti (njihove povrate "vratite" natrag u cijene, s tim da početna cijena bude jednak za oba portfelja, npr. 100). Također izračunajte analizirane srednje vrijednosti i volatilnosti svojstvenih portfelja.

#Vaš kod ide ovdje

```
c1 = eigenvectors[:, 0]
c2 = eigenvectors[:, 1]

komponenta1 = np.sign(np.sum(c1)) * c1 / np.sum(np.abs(c1))
komponenta2 = np.sign(np.sum(c2)) * c2 / np.sum(np.abs(c2))

print("Portfolio prve komponente:")
print(komponenta1)
```

```

print("Portfolio druge komponente:")
print(komponenta2)

povrati1 = np.matmul(povrati, komponenta1)
povrati2 = np.matmul(povrati, komponenta2)

vrijednostiPortfolija1 = [0] * len(povrati1)
vrijednostiPortfolija2 = [0] * len(povrati2)

vrijednostiPortfolija1[0] = 100
vrijednostiPortfolija2[0] = 100

for i in range(1, len(povrati1)):
    vrijednostiPortfolija1[i] = vrijednostiPortfolija1[i - 1] * (1 + povrati1[i])
    vrijednostiPortfolija2[i] = vrijednostiPortfolija2[i - 1] * (1 + povrati2[i])


plt.title("Portfolio values")
plt.ylabel("Value")
plt.xlabel("Time (days)")
plt.plot(list(range(len(povrati1))), vrijednostiPortfolija1, label='Prva komponenta')
plt.plot(list(range(len(povrati1))), vrijednostiPortfolija2, label='Druga komponenta')
plt.legend()
plt.show()

```

```

Portfolio prve komponente:
[0.12485224 0.12549028 0.12130324 0.11978049 0.12071949 0.12058677
 0.13323394 0.13403355]
Portfolio druge komponente:
[ 0.13182458  0.13102327  0.13183479  0.11175838 -0.14165837 -0.14159403
 -0.1053407  -0.1049659 ]

```



Ako usporedite dobivene rezultate s kretanjem cijena originalnih vrijednosnica, vidjet ćete sličnosti između vrijednosnica koje pripadaju određenim klasama imovina i pojedinih svojstvenih portfelja. Svojstveni portfelji dakle predstavljaju niže-dimenzionalan prostor tzv. sintetičkih vrijednosnica (u našem slučaju 2 umjesto originalnih 8) koje najbolje opisuju cijeli razmatrani skup podataka. Dobra procjena tih komponenti je ključna u razumijevanju zajedničkog kretanja većih skupova dionica i upravljanju financijskim rizikom.